

Análise Forense de Documentos Digitais

Prof. Dr. Anderson Rocha

anderson.rocha@ic.unicamp.br

<http://www.ic.unicamp.br/~rocha>

Reasoning for Complex Data (RECOD) Lab.
Institute of Computing, Unicamp

Av. Albert Einstein, 1251 – Cidade Universitária
CEP 13083-970 • Campinas/SP – Brasil

Spoofing em Biometria

Técnicas para Criação e Detecção


Organização

- ▶ Introdução
- ▶ Motivação
- ▶ Visão geral
 - ▶ Impressões digitais
 - ▶ Íris
 - ▶ Face
- ▶ Aprofundamento em solução anti-spoof para impressões digitais
- ▶ Aprofundamento em solução anti-spoof para face

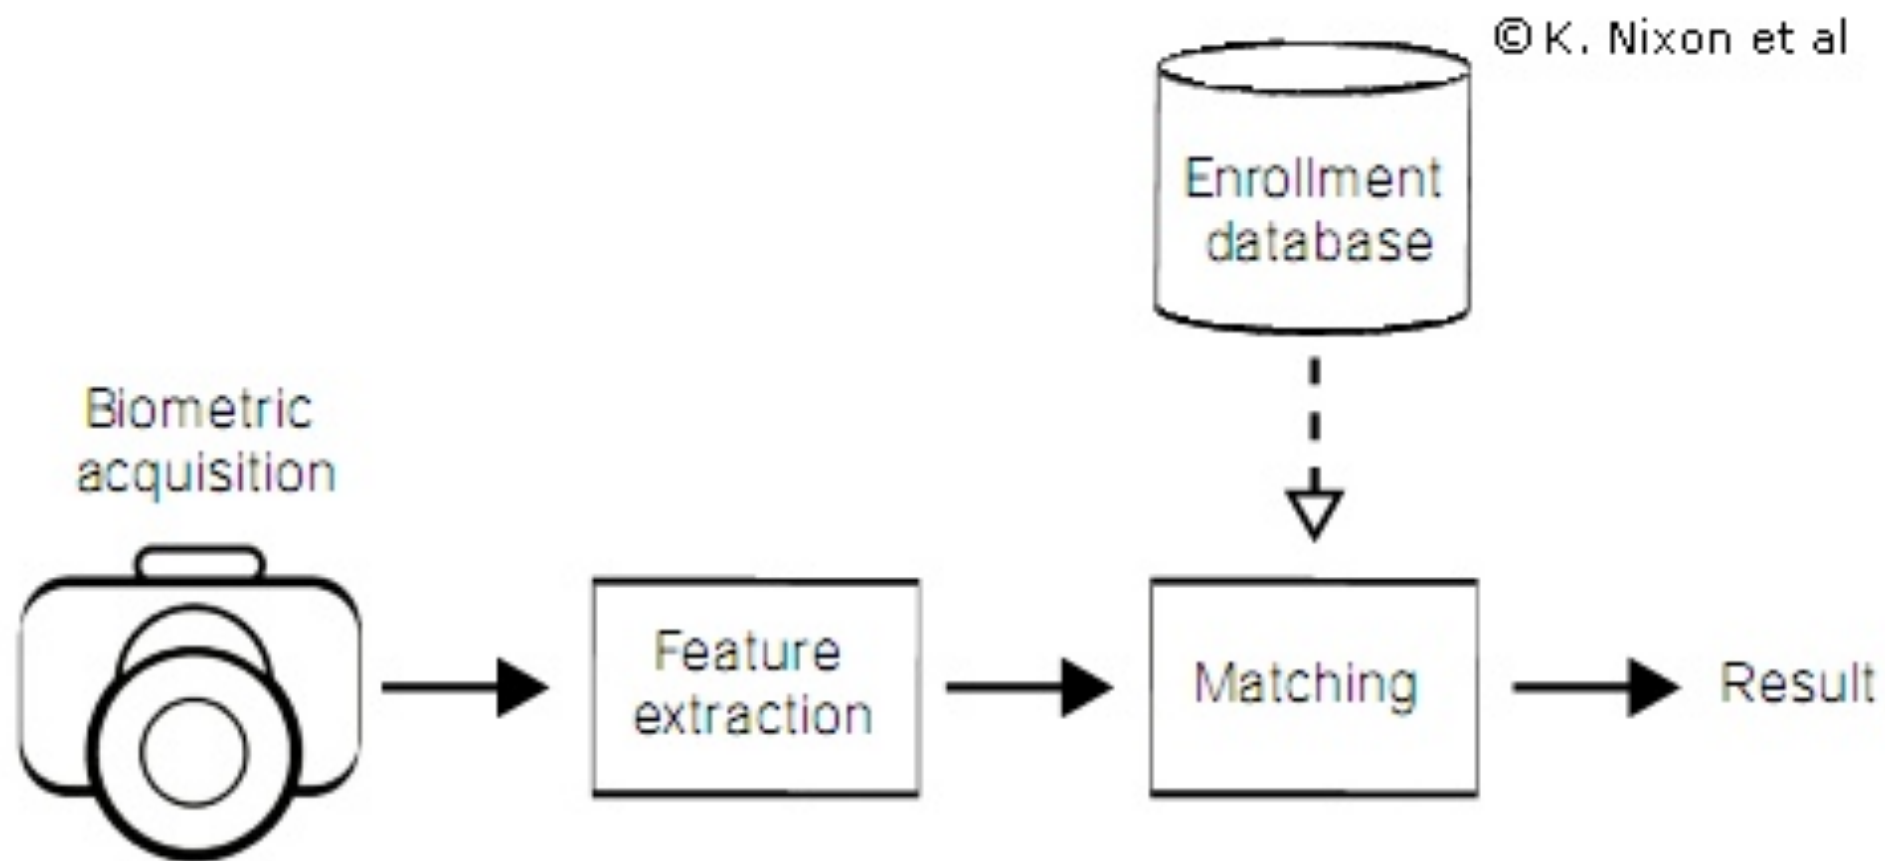
Introdução

Introdução

- ▶ **Biometria:** é um método para identificação automática de uma pessoa, baseado em características físicas ou comportamentais
 - ▶ Impressões digitais
 - ▶ Íris
 - ▶ Face



Sistema biométrico



An example of how biometric data travels to obtain a result.

Motivação



Motivação

- ▶ Aumento no uso da **Biometria**
[Thalheim et al. 2002] Impressão digital mais comum, reconhecimento facial mais aceitável; Reconhecimento de voz, de assinatura e jeito de digitar ainda pouco expressivo
- ▶ Muita pesquisa para otimizar a diferenciação entre humanos
- ▶ Pouca pesquisa (e recente) sobre a confiabilidade dos métodos, sobre como impedir ataques

Visão Geral

[Nixon et al. 2007]

Complementado com [Thalheim et al. 2002]




Ataques

- ▶ Podem visar esconder a própria identidade ou obter privilégios que outra pessoa possui
- ▶ Tipos:
 - ▶ Replay (sniffer na USB), Trojan (alterar o matcher ou o BD)
 - ▶ Spoof
 - ▶ Consiste em apresentar ao sensor um **dado biométrico falso**
 - ▶ Mais suscetível, pois todos tem acesso fácil a esta parte do processo
 - ▶ Pode ser um dedo de gelatina com uma impressão digital moldada, uma foto do rosto de alguém, uma lente de contato
 - ▶ O 1º ataque a um sistema de impressão digital data da década de 1920, por Alert Wehde, na penitenciária do Kansas

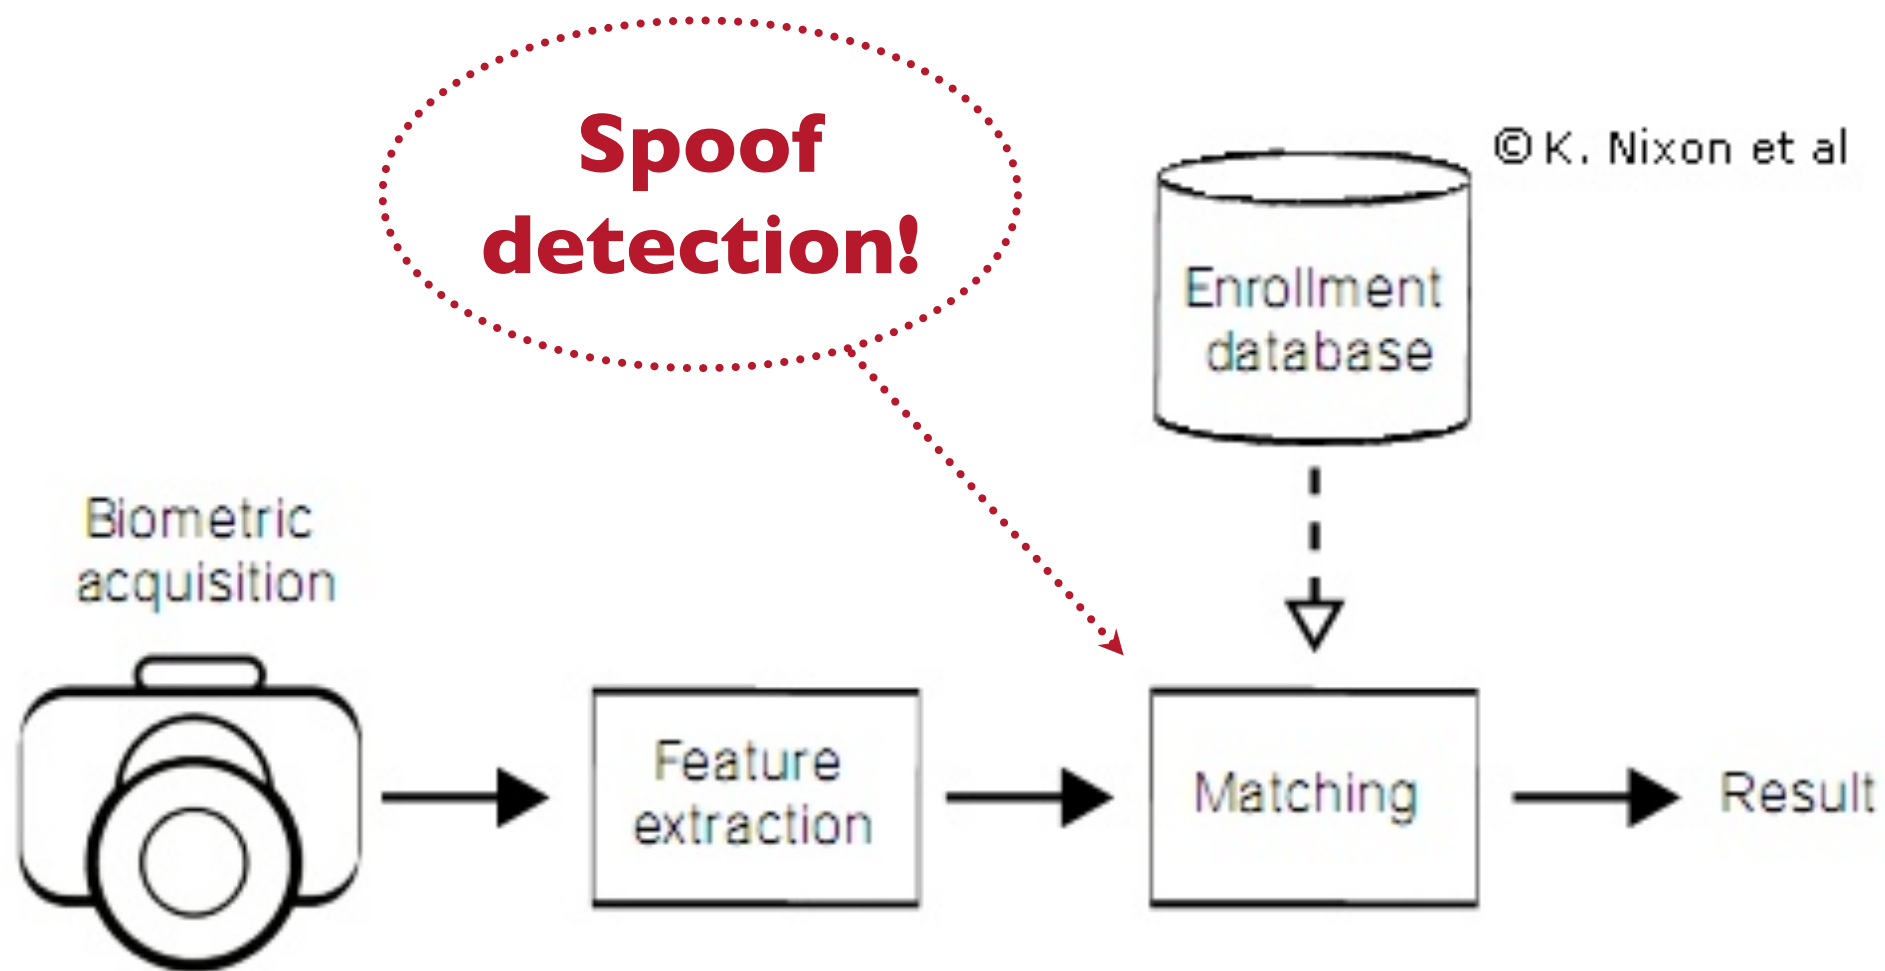


Detecção de Spoof


- ▶ Detectar se o dado biométrico realmente vem de uma pessoa viva. Pode:
 - ▶ utilizar os mesmos dados biométricos obtidos para identificação;
 - ▶ coletar mais dados no tempo;
 - ▶ ou precisar de hardware adicional



Sistema biométrico



An example of how biometric data travels to obtain a result.



Impressões digitais

“How To Fool a Fingerprint Security System As Easy As ABC”



**Make a fake fingerprint
to fool a security system**

Criação do Spoof

► Como funciona

- Se baseia na posição de detalhes (*minutiae*), como terminações e bifurcações dos sulcos
10 a 12 são suficientes para identificar unicamente uma pessoa


► Spoofs

► Impressões latentes

- Pó de grafite e fita adesiva
quase 100% de eficácia
- Respiração
nem sempre funciona
- Bolsa com água
chega a funcionar com segurança máxima



© Thalheim et al.



Criação do Spoof



► Mais Spoofs

► Dedo artificial

► Obter a impressão digital de alguém

cooperativamente ou fotografando uma impressão latente contrastada

► Moldá-la em material macio

silicone, plástico, gelatina, argila, cera ou material para molde dental

► Dedo desmembrado



Sensores para impressões digitais

► Ópticos


- **Total internal reflection (TIR):** Diferença de reflexão da luz nas cristas (em contato com o vidro) e sulcos (ar).

► Ataques:

- dedos artificiais de material com reflectância semelhante a da pele


- Impressões digitais latentes
[Thalheim et al. 2002] apenas com a fita adesiva, pó de grafite e luz

- **Multispectral imaging (MSI):** Será detalhado mais adiante



Sensores para impressões digitais

- ▶ **Ultrassom:** Diferença de velocidade das ondas acústicas entre as cristas e o ar.
 - ▶ **Ataques:**
 - ▶ dedos artificiais de gelatina (mesmas características da pele em relação a eco)




Sensores para impressões digitais

► **Capacitivos:** Diferença de capacitância entre as células sob os sulcos ou cristas.

► **Ataques:**

► Impressões digitais latentes [Thalheim et al. 2002] Fácil!


► Dedos artificiais de gelatina



► **Térmicos:** Diferença de temperatura entre cristas (em contato com o vidro) e sulcos (ar).

► **Ataques:**

► Dedos artificiais de gelatina ou silicone [Thalheim et al. 2002] Bem mais difícil de enganar do que os ópticos e capacitivos



Detecção do Spoof

▶ Transpiração

- ▶ Mudanças temporais na quantidade de suor presente na superfície do dedo
- ▶ Obter várias imagens ao longo do tempo
- ▶ Sensores capacitivos e ópticos

▶ Absorção da pele

células vermelhas do sangue, hemoglobina, oxigênio

▶ Temperatura da pele

Um spoof pode ser colocado num dedo real, mas parte da temperatura é dissipada

▶ Pulsação


Varia de pessoa para pessoa, e de acordo com sua situação atual

▶ Outras possibilidades


Resistência elétrica da pele, Detecção ultrasônica de estruturas dérmicas



Íris



Natural iris



Fake iris printed on a contact lens

© Nixon et al

Criação do Spoof

- ▶ **Como funciona**
 - ▶ Se baseia na estrutura da área texturizada do olho em torno da pupila, usa luz infravermelha
 - ▶ Cria templates com Gabor decomposition, anéis concêntricos.

© Thalheim et al.



Criação do Spoof

► Spoofs


- Foto ou vídeo do olho em alta qualidade [Thalheim et al. 2002] foto com impressora jato de tinta, 2400 x 1200 dpi, furo para a pupila
- Padrões de íris impressos em lentes de contato
- Íris artificiais tridimensionais ou com várias camadas

© Thalheim et al.




Detecção do Spoof

- ▶ Detectar movimentos involuntários dos olhos (*hippus*), ou reação à luz, ou se pisca
- ▶ Desafio-resposta (piscar, mover para um lado)
- ▶ Análise de Fourier




2D Fourier spectrum of natural iris



2D Fourier spectrum of fake iris

© Nixon et al

pressão



Face



© Tan et al.

Criação do Spoof

► Como funciona

- Tiram fotos em luz visível ou infravermelha.
- O match se baseia em características como a distância entre os olhos.
- Podem ser 2D ou 3D.

► Spoofs

- Foto impressa da pessoa
- Vídeo da pessoa na tela de um notebook/celular
- Modelos tridimensionais




Detecção do Spoof

- ▶ Movimentos involuntários do rosto, cabeça, piscar dos olhos
- ▶ Textura da pele, refração de acordo com o tipo de luz
- ▶ Reflexão da luz 2D *versus* 3D [Tan et al. 2010]
- ▶ Análise de Fourier da imagem
- ▶ Sensor tridimensional
- ▶ Desafio-resposta (piscar, sorrir, falar frases)



Reflexões [Thalheim et al. 2002]

- ▶ Os dispositivos testados não são para ambientes de segurança máxima, mas...
- ▶ Vale o **custo X benefício**, se são facilmente enganados?
- ▶ Os dispositivos biométricos já tem condições de substituir as **senhas**?



Multispectral Imaging em impressões digitais

[Nixon et al. 2007]



Sensor

- ▶ Sensor de impressões digitais baseado em MSI, produzido pela **Lumidigm** – J110
- ▶ Configurado para obter imagens da **superfície** e **subsuperfície do dedo** em várias condições ópticas.
- ▶ **Características ópticas** da subsuperfície discriminam entre peles verdadeiras e falsas
- ▶ Combinação possibilita obter dados biométricos sob diversas condições fisiológicas e ambientais.
Luz ambiente forte, umidade, pouco contato entre o dedo e o sensor, pele seca



Princípios de Operação

- ▶ Imagens capturadas sob características diferentes: informações diferentes e complementares.
- ▶ **Frequências de luz** diferentes: penetram a pele em diferentes profundidades.
- ▶ **Polarizações** diferentes: mudam o grau de contribuição das características da superfície e subsuperfície da pele na imagem.
- ▶ **Orientações de luz** diferentes: mudam o local e a intensidade com que características da superfície são acentuadas.





Teste de Spoof

- ▶ 3 sensores, 118 voluntários entre 18 e 80 anos
- ▶ Visitas ao longo de 3 semanas, não foram instruídos a lavar as mãos ou tratar os dedos previamente.
- ▶ Total de **49 tipos de spoof**: Latex, silicone, massa de modelar, argila, borracha, cola, resina, gelatina e fita foram utilizadas em várias cores, concentrações e espessuras.
- ▶ Um total de 17.454 imagens foram coletadas de dedos reais e 27.486 imagens falsas. Para cada classe de spoof, entre 40 e 1940 amostras foram coletadas, sendo os spoofs transparentes os que mais tiveram amostras.
- ▶ Cada imagem foi processada utilizando wavelets para a extração de características baseadas nas informações espectrais e de textura disponíveis. 8 características foram utilizadas para classificação.



Teste de Spoof

- ▶ Para calcular o trade-off do erro entre Verdadeiro Positivo e Falso Positivo, foram utilizadas as médias das distâncias euclidianas para as classes de pessoa e spoof.
- ▶ Verdadeiro Positivo: 99.5%
- ▶ Falso Positivo: 0.9%.
- ▶ Nesse ponto muitos tipos de spoof nunca eram aceitos e nenhum caso de spoof tinha uma taxa de falso positivo maior que 15%.
- ▶ **Detecção de spoof robusta** em sensores MSI com mínimo impacto para o usuário genuíno.



Face Liveness Detection from a Single Image with Sparse Low Rank Bilinear Discriminative Model

[Tan et al. 2010]



Face Liveness Detection

- ▶ A idéia
 - ▶ Uma face humana real – 3D
 - ▶ Face em uma foto – 2D
 - ▶ A rugosidade de uma face real é diferente da de uma foto.



Face Liveness Detection

► O Modelo

- Duas imagens: $I_t(x, y)$, de uma face humana real, e $I_f(x, y)$ de uma face impostora. Qual a diferença delas?

► Suposição de reflectância Lambertiana

- Superfície da face é modelada como um reflector difuso ideal.
- De acordo com a lei do cosseno de Lambert, a intensidade de uma imagem de face é descrita como:

$$I(x, y) = f_c(x, y) \rho(x, y) A_{light} \cos \theta$$

Onde $f_c(x, y)$ depende da câmera, A_{light} é a intensidade da luz e $\rho(x, y)$ representa a reflectância da superfície.




Face Liveness Detection

- ▶ $\cos\theta = n \cdot s$ é o ângulo entre a normal e o raio de luz.
- ▶ $A_{light}(n \cdot s) \triangleq \mu(x, y)$ é a iluminância da imagem.
- ▶ Sendo $f_c(x, y)$ constante, as imagens real e impostora podem ser descritas como:

$$I_t(x, y) = \rho_t(x, y)\mu_t(x, y),$$

$$I_f(x, y) = \rho_f(x, y)\mu_f(x, y).$$

- ▶ Sob as mesmas condições de iluminação, a diferença entre as imagens é obtida comparando as propriedades de superfície, reflectância e normal.



Face Liveness Detection

- ▶ É possível estimar os valores para $\rho(x, y)$ e $\mu(x, y)$ através de uma série de amostras.

- ▶ **Método baseado em Variational Retinex**

- ▶ Primeiro se estima a iluminância, para depois estimar a reflectância.
- ▶ O método Logarithmic Total Variation (LTV) é usado para estimar a iluminância, através da fórmula

$$\mu = \min \int_{image} || \nabla \mu ||^1 + \lambda | I - \mu |$$


λ é um parâmetro de fidelidade de dados (utilizado 0.5 no paper)

- ▶ Tendo μ pode-se estimar ρ com a fórmula de Land Retinex:
$$\log(\rho(x, y)) = \log(I(x, y) + 1) - \log(\mu(x, y) + 1)$$





Face Liveness Detection

- ▶ Método baseado em Diferença de Gaussianas (DoG)
- ▶ Analisa o espectro 2D de Fourier: frequências muito altas são ruidosas, utilizar as médias-altas
- ▶ Para manter o máximo de detalhes possível sem introduzir ruído ou aliasing, nesse trabalho são usadas gaussianas interna de $\sigma_0 = 0.5$ e externa de $\sigma_1 = 1.0$.




© Li et al.





© Tan et al.

- ▶ Linha superior: Imagens reais, Linha inferior: Imagens recapturadas
- ▶ Da esquerda para a direita:
 - ▶ 1) Imagem original;
 - ▶ 2) Imagem μ estimada com LTV; 3) Imagem ρ estimada com LTV
 - ▶ 4) Espectro de Fourier centralizado da imagem original; 5) Espectro de Fourier centralizado da imagem filtrada com DoG



► A Classificação


- Treinado diretamente com as amostras, sem mais extrações de características.

► Sparse Logistic Regression

- Seja $\mathbf{x} \in \mathcal{R}^n$ uma amostra e $y \in \{-1, 1\}$ a classe binária associada: Imagem falsa = +1, verdadeira = -1.
- O modelo de regressão logística é dado por:

$$\text{Prob}(y | \mathbf{x}) = \frac{1}{1 + \exp(-y(\mathbf{w}^T \mathbf{x} + b))}$$

- $\text{Prob}(y | \mathbf{x})$ é a probabilidade condicional da classe $y = 1$, dada uma amostra \mathbf{x} , $\mathbf{w} \in \mathcal{R}^n$ é um vetor de pesos, $b \in \mathcal{R}$ e é a intersecção.



Face Liveness Detection


- Sendo um conjunto de m dados de treinamento, $\{\mathbf{x}_i, y_i\}_{i=1}^m$ a **função de probabilidade** associada é definida como

$$\prod_{i=1}^m \text{Prob}(y_i | \mathbf{x}_i)$$

- O negativo do logaritmo da função de probabilidade é chamado de **perda logística**, e perda logística média é definida como:

$$\begin{aligned} \text{loss}(w, b) &= -\frac{1}{m} \log \prod_{i=1}^m \text{Prob}(y_i | \mathbf{x}_i) \\ &= \frac{1}{m} \sum_{i=1}^m \log(1 + \exp(-y_i(\mathbf{w}^T \mathbf{x}_i + b))) \end{aligned}$$

- Podemos determinar \mathbf{w} e b minimizando a média de perda logística.



Face Liveness Detection

- ▶ **Sparse Low Rank Bilinear Logistic Regression**
 - ▶ Opera sobre a representação bi-dimensional das imagens, para explorar as suas propriedades espaciais.
 - ▶ Objetivo é aprender uma matriz de projeção de posto baixo. – Número de linhas ou colunas linearmente independentes é baixo.
- ▶ **Non Linear Model via Empirical Mapping**
 - ▶ Transforma o mapeamento definido sobre as amostras de treinamento num espaço de características.
 - ▶ Usa SVM probabilístico, Relevance Vector Machine e Import Vector Machine




Face Liveness Detection

► Experimentos

- Fotos de alta definição com uma câmera Canon, de modo que a face ocupa $\frac{2}{3}$ da área da foto.
- Impressão das fotos em papel fotográfico e em papel A4 70g. Fotos tiradas das fotografias impressas.



© Tan et al




Face Liveness Detection

► Experimentos

	Session1	session2	session3	Total
Training Set				
Client	889	854	0	1,743
Imposter	855	893	0	1,748
Total	1,744	1,747	0	3,491
Test Set				
Client	0	0	3,362	3,362
Imposter	0	0	5,761	5,761
Total	0	0	9,123	9,123

- Normalização geométrica: detecção de face e corte, rotação e escala para fixar as posições dos centros dos olhos. Imagens fixadas em 64x64 pixels e conversão para escala de cinza de 8 bits.






Face Liveness Detection

► Resultados




► Sparse linear logistic regression

- **RAW**: Imagem Original; **LTV_p**: Imagem ρ estimada com LTV; **LTV_u**: Imagem μ estimada com LTV; **DoG**: Imagem com filtro DoG; **HF**: Filtro em 1/3 das mais altas frequências.



Face Liveness Detection

- ▶ Resultados
- ▶ Sparse nonlinear logistic regression e comparação



Conclusões



Conclusões

- ▶ **Jogo de gato e rato:** novas técnicas de detecção, novos ataques
- ▶ São necessárias pesquisas, independentes dos fabricantes, para medir a segurança e apontar falhas
- ▶ Há vários métodos anti-spoof que parecem promissores, como o MSI da Lumidigm para impressões digitais e o [Tan et al. 2010] para face, mas só com testes no mundo real podemos afirmar

Referências



Referências

- **[Nixon et al. 2007]** Kristin Adair Nixon, Valerio Aimale, and Robert K. Rowe. Spoof detection schemes. White paper, Lumidigm Inc., 2007.
- **[Thalheim et al. 2002]** L. Thalheim, J. Krissler, P.-M. Ziegler; Body Check: Biometric Access Protection Devices and their Programs Put to the Test. Heise Online. November 2002
- **[Tan et al. 2010]** Tan, X.; Li, Y.; Liu, J.; Jiang, L.: Face Liveness Detection from A Single Image with Sparse Low Rank Bilinear Discriminative Model. In European Conference on Computer Vision (2010)
- **[Li et al. 2004]** Jiangwei Li , Yunhong Wang , Tieniu Tan , A. K. Jain: Live face detection based on the analysis of Fourier spectra. In Biometric Technology for Human Identification (2004)

Obrigado!
